A L G O R I T H M

P R A C T I C E

Python网络爬虫基础

Steven Tang

渡一教育
Duyi Education

主要内容：

- 网络爬虫基本概念
- requests 库
- urllib库
- beautifulsoup4 库
- re库

网络爬虫基本概念：


```
<!DOCTYPE html>
<!-- [ published at 2020-06-27 11:39:00 ] -->
<html>
<head>
    <meta http-equiv="Content-type" content="text/html; charset=utf-8" />
    <meta http-equiv="X-UA-Compatible" content="IE=edge" />
    <title>新浪首页</title>
    <meta name="keywords" content="新浪,新浪网,SINA,sina,sina.com.cn,新浪首页,门户,资讯" />
    <meta name="description" content="新浪网为全球用户24小时提供全面及时的中文资讯，内容覆盖国内外突发新闻事件、体坛赛事、娱乐时
动交流空间。" />
    <meta content="always" name="referrer">
    <link rel="mask-icon" sizes="any" href="//www.sina.com.cn/favicon.svg" color="red">
    <meta name="stencil" content="PGLS000022" />
    <meta name="publishid" content="30,131,1" />
    <meta name="verify-v1" content="6HtwmypggdgP1NLw7NOuQBI2TW8+CfkYCoyeB8IDbn8=" />
    <meta name="application-name" content="新浪首页"/>
    <meta name ="msapplication-TileImage" content="//i1.sinaimg.cn/dy/deco/2013/0312/logo.png"/>
    <meta name="msapplication-TileColor" content="#ffbf27"/>
<link rel="apple-touch-icon" href="//i3.sinaimg.cn/home/2013/0331/U586P30DT20130331093840.png" />

    <script type="text/javascript">
    //js异步加载管理
    (function(){var w=this,d=document,version='1.0.7',data={},length=0,cbkLen=0;if(w.jsLoader){if(w.jsLoader.version>=version){r
{obj.attachEvent("on"+eventType,func)}else{obj.addEventListener(eventType,func,false)}};var domReady=false,ondomReady=function()
<525){doReadyStateCheck()}else{d.addEventListener("DOMContentLoaded",function(){d.removeEventListener("DOMContentLoaded",argumen
{return};try{d.documentElement.doScroll("left")}catch(e){return};ondomReady()};function doReadyStateCheck(){if(domReady){return}
{ondomReady();return}else{setTimeout(doReadyStateCheck,1);return}};function createPosNode(){if(jsLoader.caller){return};cbkLen++
id="_jl_pos_'+cbkLen+'"></div>');s=d.getElementById('_jl_pos_'+cbkLen)}catch(e){var s=d.createElement('div');s.id='_jl_pos_'+cbk
s=d.createElement('div');s.id='_jl_pos_'+cbkLen;s.style.display='none';d.body.appendChild(s)};return s};function getScript(url,d
{scriptNode.charset=charset};scriptNode.onreadystatechange=scriptNode.onload=function(){if(!this.readyState||this.readyState=="l
{dispose()};scriptNode.onreadystatechange=scriptNode.onload=null;scriptNode.parentNode.removeChild(scriptNode)}};scriptNode.src=
cWrite(str){if(posNode.childNodes.length>0){return};if(posNode.innerHTML!='){while(posNode.childNodes.length){posNode.parentNod
{posNode.parentNode.insertBefore(posNode.childNodes[0],posNode)}};var JsObj=function(name,url){this.name=name;this.url=url;this.
i=0;i<this.callback.length;i++){if(typeof this.callback[i]='function'){try{if(this.callback[i].posNode){posNode=this.callback[i
{d.write=write;this.callback[i].posNode.parentNode.removeChild(this.callback[i].posNode)}catch(e){errors.push(e)}}};this.callba
callback=cfg.callback||"";var charset=cfg.charset||"";if(name){if(!data[name]){if(!url){data[name]=new JsObj(name);data[name].st
{data[name].status='init'};if(cfg.status){data[name].status=cfg.status};if(data[name].status='loading'||data[name].status='wai
if(data[name].status='ok'){if(typeof callback='function'){callback()};return}else{if(!url){return};for(var item in data){if(d
JsObj(name,url);length++};if(data[name].status='loading'){if(typeof callback='function'){callback.posNode=createPosNode();data
{callback()};return};if(typeof callback='function'){callback.posNode=createPosNode();data[name].callback.push(callback)};getSc
{data[name].onload()},charset);data[name].status='loading'};w.jsLoader.version=version;w.jsLoader.getData=function(){return data

    </script>

<!--iplook接口如果故障，首页舌签切换将失效，此为iplook接口的容错，默认为北京市-->
<script>
//空对象返回true
```

requests 库

- requests 库是一个简洁的处理HTTP请求的第三方库，它的程序编写过程更接近正常URL 访问过程。

```
In [6]: import requests

In [7]: r=requests.get("http://www.baidu.com")

In [8]: type(r)
Out[8]: requests.models.Response
```

requests 库 response的属性

属性	描述
status_code	HTTP请求返回状态，200表示正常，404表示失败
text	HTTP响应内容
encoding	HTTP响应编码方式
content	HTTP响应的二进制方式
json	如果HTTP响应内容包含JSON数据，该方法解析JSON数据
raise_for_status()	如果status_code不是200，则报异常。

requests 库

```
In [19]: response=requests.get('http://www.baidu.com')

In [20]: response.text
Out[20]: '<!DOCTYPE html>\r\n<!--STATUS OK--><html> <head><meta http-equiv=content-type
content=text/html;charset=utf-8><meta http-equiv=X-UA-Compatible content=IE=Edge><meta
content=always name=referrer><link rel=stylesheet type=text/css href=http://s1.bdstatic.com/r/www/
cache/bdorz/baidu.min.css><title>ç\x99¾åº¦ä¸\x80ä¸\x8bï¼\x8cä½\xa0å°±ç\x9f¥é\x81\x93</title></head>
<body link=#0000cc> <div id=wrapper> <div id=head> <div class=head_wrapper> <div class=s_form> <div
class=s_form_wrapper> <div id=lg> <img hidefocus=true src=//www.baidu.com/img/bd_logo1.png
width=270 height=129> </div> <form id=form name=f action=//www.baidu.com/s class=fm> <input
type=hidden name=bdorz_come value=1> <input type=hidden name=ie value=utf-8> <input type=hidden
name=f value=8> <input type=hidden name=rsv_bp value=1> <input type=hidden name=rsv_idx value=1>
<input type=hidden name=tn value=baidu><span class="bg s_ipt_wr"><input id=kw name=wd class=s_ipt
value maxlength=255 autocomplete=off autofocus></span><span class="bg s_btn_wr"><input type=submit
id=su value=ç\x99¾åº¦ä¸\x80ä¸\x8b class="bg s_btn"></span></form></div></div><div id=u1><a
```

```
In [21]: response.encoding='utf-8'

In [22]: response.text
Out[22]: '<!DOCTYPE html>\r\n<!--STATUS OK--><html> <head><meta http-equiv=content-type
content=text/html;charset=utf-8><meta http-equiv=X-UA-Compatible content=IE=Edge><meta
content=always name=referrer><link rel=stylesheet type=text/css href=http://s1.bdstatic.com/r/www/
cache/bdorz/baidu.min.css><title>百度一下，你就知道</title></head> <body link=#0000cc> <div
id=wrapper> <div id=head> <div class=head_wrapper> <div class=s_form> <div class=s_form_wrapper>
<div id=lg> <img hidefocus=true src=//www.baidu.com/img/bd_logo1.png width=270 height=129> </div>
<form id=form name=f action=//www.baidu.com/s class=fm> <input type=hidden name=bdorz_come value=1>
<input type=hidden name=ie value=utf-8> <input type=hidden name=f value=8> <input type=hidden
name=rsv_bp value=1> <input type=hidden name=rsv_idx value=1> <input type=hidden name=tn
value=baidu><span class="bg s_ipt_wr"><input id=kw name=wd class=s_ipt value maxlength=255
autocomplete=off autofocus></span><span class="bg s_btn_wr"><input type=submit id=su value=百度一下
```

requests 库 post 方法

```
In [25]: data = {'key1':'value1','key2':'value2'}

In [26]: r =requests.post('http://httpbin.org/post',data)

In [27]: r.status_code
Out[27]: 200
```

GET和POST两种基本请求方法的区别

Urllib库

- Urllib是Python提供的一个用于操作URL的模块，我们爬取网页的时候，经常需要用到这个库。

Urllib库

- urllib.request---请求模块，用于发起网络请求
- urllib.parse---解析模块，用于解析URL
- urllib.error---异常处理模块，用于处理request引起的异常

urllib.request模块

request模块主要负责构造和发起网络请求，并在其中添加Headers，Proxy等。 利用它可以模拟浏览器的请求发起过程。

- 发起网络请求
- 添加Headers

beautifulsoup4 库概述

- HTML 建立的Web 页面一般非常复杂，除了有用的内容信息外，还包括大量用于页面格式的元素，直接解析一个Web 网页需要深入了解HTML 语法，而且比较复杂。beautifulsoup4 库将专业的Web 页面格式解析部分封装成函数，提供了若干有用且便捷的处理函数。

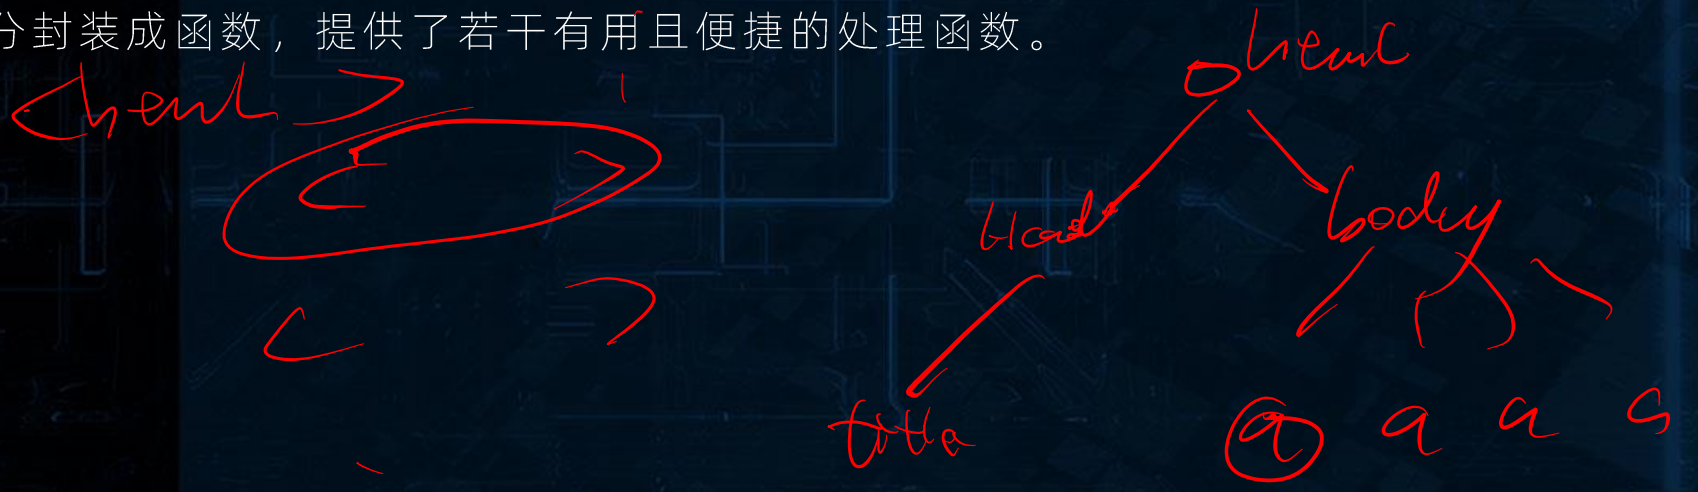

beautifulsoup4 库概述

- 使用requests 库获取HTML 页面并将其转换成字符串后，需要进一步解析HTML页面格式，提取有用信息，这需要处理HTML 和XML 的函数库。
- beautifulsoup4 库，也称为Beautiful Soup 库或bs4 库，用于解析和处理HTML和XML。

beautifulsoup4 库概述

- beautifulsoup4 库采用面向对象思想实现，简单说，它把每个页面当做一个对象，通过<a>.<b>的方式调用对象的属性（即包含的内容），或者通过<a>.<b>()的方式调用方法（即处理函数）。

beautifulsoup4 库概述

属性	描述
head	HTML页面的<head>内容
title	HTML页面标题 <title>
body	HTML页面<body>
p	HTML页面第一个<p>内容
strings	HTML页面所有标签的内容
stripped_strings	HTML页面所有非空格字符串

BeautifulSoup 对象的常用属性

- 其中，尖括号（<>）中的标签的名字是name，尖括号内其他项是attrs，尖括号之间的内容是string。

  因此，可以通过Tag 对象的name、attrs 和string 属性获得相应内容，采用<a>.<b>的语法形式。

- 标签Tag 有4 个常用属性

beautifulsoup4 库概述

属性	描述
name	字符串，标签的名字
attrs	字典，包含了原有页面tag的属性
contents	列表，这个tag下的所有内容
strings	tag中包含的文本

find_all方法查找所有

BeautifulSoup.find_all(name, attrs, recursive, string, limit)

作用：根据参数找到对应标签，返回列表类型。

参数：

name：按照 Tag 标签名字检索，名字用字符串形式表示，例如：div，li；

attrs：按照 Tag 标签属性值检索，需要列出属性名称和值，采用 JSON 表示；

recursive： 设置查找层次，只查找当前标签下一层时使用 recursive=False；

string：按照关键字检索 string 属性内容，采用 string=开始；

limit：返回结果的个数，默认返回全部结果。

re库

什么是正则表达式：

正则表达式，又称规则表达式，通常被用来检索、替换那些符合某个模式(规则)的文本。

正则表达式是对字符串操作的一种逻辑公式，就是用事先定义好的一些特定字符、及这些特定字符的组合，组成一个"规则字符串"，这个"规则字符串"用来表达对字符串的一种过滤逻辑。

常用操作符（1）

属性	描述	
.	表示任意单个字符	
[ ]	字符集	[abc]表示a、b、c，[a-z]表示a到z的单个字符
[^]	非字符集	[^abc]表示 非a非b非c的单个字符
*	前一个字符0次或者无限次扩展	abc* 表示 ab, abc, abcc, abccc等
+	前一个字符1次或者无限次扩展	abc+ 表示 abc，abcc，abccc等
?	前一个字符1次或者0次扩展	abc? 表示 abc 或者ab
|	左右表达式任意一个	abc|def 表示 abc 或者 def

常用操作符的组合

- 表达式 .* 就是单个字符匹配任意次，即贪婪匹配。表达式 .*? 是满足条件的情况只匹配一次，即最小匹配（懒惰匹配）.

操作符	描述
*?	重复任意次，尽量少重复
+?	重复1次以上，尽量少重复
? ?	重复0到1次，尽量少重复
{n,m}?	重复n到m次，尽量少重复
{n,}?	重复n次以上，尽量少重复

```
In [41]: ls=re.findall("a.*b","abcdb")

In [42]: ls
Out[42]: ['abcdb']

In [43]: ls=re.findall("a.*?b","abcdb")

In [44]: ls
Out[44]: ['ab']
```

常用操作符（2）

属性	描述	
{m}	扩展一个字符m次	Ab{4}c 表示 Abbbbc
{m,n}	扩展一个字符m至n次	Ab{2,4}c 表示 Abbc, Abbbc, Abbbbc
^	匹配字符串开头	^abc 表示以abc 开头的字符串
$	匹配字符串结尾	$abc 表示以abc 结尾的字符串
+	前一个字符1次或者无限次扩展	abc+ 表示 abc，abcc，abccc等
?	前一个字符1次或者0次扩展	abc? 表示 abc 或者ab
\d	数字，等价于[0-9]	
\w	单词字符,等价于[a-zA-Z0-9_]	

re.match

- re.match(pattern, string)
- 从一个字符串的开始位置起匹配正则表达，返回match对象

re. Match object

```
In [49]: re.match('\d{3}','abc123,444hhh,weather0000')

In [50]: re.match('\d{3}','123abc,444hhh,weather0000')
Out[50]: <re.Match object; span=(0, 3), match='123'>
```

邮箱的正则表达式

- ^[a-zA-Z0-9_-]+@[a-zA-Z0-9_-]+(\.[a-zA-Z0-9_-]+)+$

```
In [36]: re.match(r'^[a-zA-Z0-9_-]+@[a-zA-Z0-9_-]+(\.[a-zA-Z0-9_-]+)+
$','ilovepython@qq.com')
Out[36]: <re.Match object; span=(0, 18), match='ilovepython@qq.com'>

In [37]: re.match(r'^[a-zA-Z0-9_-]+@[a-zA-Z0-9_-]+(\.[a-zA-Z0-9_-]+)+
$','ilove python@qq.com')

In [38]: re.match(r'^[a-zA-Z0-9_-]+@[a-zA-Z0-9_-]+(\.[a-zA-Z0-9_-]+)+
$','__python@qq.com')
Out[38]: <re.Match object; span=(0, 15), match='__python@qq.com'>

In [39]: re.match(r'^[a-zA-Z0-9_-]+@[a-zA-Z0-9_-]+(\.[a-zA-Z0-9_-]+)+
$','__python@qq.com.cn')
Out[39]: <re.Match object; span=(0, 18), match='__python@qq.com.cn'>

In [40]: re.match(r'^[a-zA-Z0-9_-]+@[a-zA-Z0-9_-]+(\.[a-zA-Z0-9_-]+)+
$','__python@qq.com.cn.org')
Out[40]: <re.Match object; span=(0, 22), match='__python@qq.com.cn.org'>

In [41]: re.match(r'^[a-zA-Z0-9_-]+@[a-zA-Z0-9_-]+(\.[a-zA-Z0-9_-]+)+
$','__python@.org')
```

re.search

- re.search(pattern, string)

- 在一个字符串中搜索匹配正则表达式的第一个位置，返回match对象
  - pattern：正则表达式的字符串或原生字符串表示
  - string：待匹配字符串

```
In [48]: re.search('\d{3}','abc123,444hhh,weather0000').group(0)
Out[48]: '123'
```

re.findall

- re.findall(pattern, string)

  搜索字符串，以列表类型返回全部能匹配的子串

  · pattern：正则表达式的字符串或原生字符串表示

  · string：待匹配字符串

```
In [24]: import re

In [25]: ls=re.findall(r'\d{6}','ABCDE1000000, FGHIJG234567')

In [26]: ls
Out[26]: ['100000', '234567']

In [27]: ls=re.findall(r'\d{5}','ABCDE1000000, FGHIJG234567')

In [28]: ls
Out[28]: ['10000', '23456']

In [29]: ls=re.findall(r'\d{3}','ABCDE1000000, FGHIJG234567')

In [30]: ls
Out[30]: ['100', '000', '234', '567']
```

compile 函数

- compile 函数用于编译正则表达式，生成一个 Pattern 对象，它的一般使用形式如下：

```
In [53]: pattern=re.compile('\d{3}')

In [54]: re.match(pattern,'123abc,444hhh,weather0000')
Out[54]: <re.Match object; span=(0, 3), match='123'>
```

案例一：从电影页面爬取豆瓣评论数据

案例二：从百度图片爬取图片

作业

- 编写一个电影评论爬虫程序，要求用户能够输入电影名称，然后将评论和评级存入一个txt文件。